

lchat

Agent coding mini untuk terminal, dijalankan dengan model Qwen lewat LiteLLM atau OpenRouter.

Target Ubuntu 24.04

Hasil build satu binary static ± 7 MB, tanpa dependency

Model uji qwen/qwen3.5-35b-a3b

Semua tangkapan layar di panduan ini diambil dari sesi sungguhan di Ubuntu 24.04, bukan ilustrasi. Path folder dipendekkan jadi `~/demo`, dan key pada contoh sengaja dipalsukan.

1 Build dan install

Butuh Go 1.22 atau lebih baru (`sudo apt install golang-go`). Dari folder sumber:

```
CGO_ENABLED=0 go build -trimpath -ldflags="-s -w" -o lchat .  
install -Dm755 lchat ~/.local/bin/lchat # opsional, agar bisa dipanggil dari mana saja
```

```
$ go build -o lchat .  
  
-rwxrwxr-x 1 developer developer 7.2M Sep 20 05:03 lchat  
lchat: ELF 64-bit LSB executable, x86-64, version 1 (SYSV), statically linked, Go BuildID=kr
```

Hasilnya satu file yang berdiri sendiri. Tidak ada runtime atau library yang perlu dipasang di mesin tujuan.

Tanpa Go? Cukup salin binary `lchat` dari mesin lain dengan arsitektur sama; ia statically linked.

2 Lihat semua opsi

Menjalankan `lchat` tanpa argumen langsung masuk mode interaktif. Untuk melihat daftar flag:

```
$ lchat -h

lchat: agent coding mini untuk terminal (LiteLLM / OpenAI-compatible)

Pakai:
  lchat [flag]                mode interaktif
  lchat [flag] -p "tugas"      sekali jalan (jawaban ke stdout, aktivitas ke stderr)
  lchat -i shot.png -p "apa ini?" kirim gambar
  lchat probe [-m model] [--save] deteksi cara thinking & tool call sebuah model

Env: LCHAT_BASE_URL, LCHAT_API_KEY, LCHAT_MODEL, LCHAT_CTX, LCHAT_TOOL_MAX,
     LCHAT_TEMPERATURE, LCHAT_MODELS (file profil, default ~/.config/lchat/models.json)
Tanpa LCHAT_BASE_URL/LCHAT_API_KEY tapi ada OPENROUTER_API_KEY: langsung ke OpenRouter.
Semua variabel ini juga dibaca dari ~/.env, .env di samping binary lchat,
dan ~/.config/lchat/.env.

Flag:
  -check-ts
    auto-check file .ts dengan tsc --noEmit (lambat)
  -i value
    lampirkan gambar (boleh diulang)
  -m string
    nama model (alias di LiteLLM) (default "qwen/qwen3.5-35b-a3b")
  -max-steps int
    batas langkah per giliran (default 30)
  -mode string
    mode kerja: plan | ask | auto (Tab untuk ganti) (default "ask")
  -p string
```

3 Cara termudah: wizard /config

Alih-alih menyunting file, jalankan wizard-nya. Ia menanyakan endpoint, API key (diketik tersamar), lalu mengambil daftar model dari endpoint itu memakai key yang baru diisi, sehingga kamu tinggal memilih nomornya.

```
lchat config      # dari terminal
/config           # dari dalam sesi lchat
```

```
$ lchat config
konfigurasi lchat · Enter = pakai nilai sekarang · Ctrl+C batal
  1) OpenRouter (langsung, butuh API key OpenRouter)
  2) LiteLLM atau endpoint OpenAI-compatible lain (alamat + key)

pilih [1] > 1

API key OpenRouter [sk-or-v1-a*****a0a4] > .....
.....
mengambil daftar model...
447 model tersedia untuk key ini

filter model (mis. qwen3.5; kosong = semua) > qwen3.5
  1) qwen/qwen3.5-122b-a10b      256k · tools · gambar · $0.26/$2.08 per 1M
  2) qwen/qwen3.5-27b           256k · tools · gambar · $0.20/$1.56 per 1M
  3) qwen/qwen3.5-35b-a3b       256k · tools · gambar · $0.31/$1.25 per 1M
  4) qwen/qwen3.5-397b-a17b     256k · tools · gambar · $0.55/$3.50 per 1M
  5) qwen/qwen3.5-9b            256k · tools · gambar · $0.10/$0.15 per 1M
  6) qwen/qwen3.5-9b:batch      256k · tools · gambar · $0.17/$0.25 per 1M
  7) qwen/qwen3.5-flash-02-23   976k · tools · gambar · $0.07/$0.26 per 1M
  8) qwen/qwen3.5-plus-02-15    976k · tools · gambar · $0.26/$1.56 per 1M
  9) qwen/qwen3.5-plus-20260420 976k · tools · gambar · $0.30/$1.80 per 1M

pilih nomor, ketik id model, atau kosong untuk filter ulang > 1
tersimpan di ~/demo/config.json
endpoint: https://openrouter.ai/api/v1
key: sk-or-v1-a*****a0a4
model: qwen/qwen3.5-122b-a10b · profil qwen3-openrouter (bawaan; thinking: body; ctx 64k)

jalankan probe untuk mengenali model ini sekarang? [y/N] n
percakapan direset agar memakai konfigurasi baru
```

Daftar model menampilkan ukuran konteks, dukungan tool dan gambar, serta harga per 1 juta token. Hasil pilihan disimpan di `~/.config/lchat/config.json` dengan izin `600` dan langsung dipakai sesi yang sedang berjalan. Di akhir, wizard menawarkan menjalankan `probe`.

Urutan sumber konfigurasi, dari yang paling menang: flag command line, environment variable, file `.env`, lalu `config.json` dari wizard. Kalau ada yang menimpa hasil wizard, lchat memberi tahu saat menyimpan.

4 Kalau ingin mengatur manual

Ada dua jalur, dan keduanya dikonfigurasi lewat file `.env` atau environment variable.

Jalur	Kapan dipakai	Yang perlu diisi
A. OpenRouter langsung	paling cepat dimulai, tanpa server tambahan	<code>OPENROUTER_API_KEY</code>
B. LiteLLM proxy	model lokal (vLLM/Ollama), banyak model di satu alamat, pencatatan biaya, kunci bersama satu tim	<code>LCHAT_BASE_URL</code> , <code>LCHAT_API_KEY</code> , <code>LCHAT_MODEL</code>

Urutan pembacaan konfigurasi: environment variable lebih dulu, lalu `./.env` di folder kerja, lalu `.env` di samping binary `lchat`, lalu `~/.config/lchat/.env`. Isi `.env` tidak pernah diteruskan ke perintah yang dijalankan agent.

4A Jalur A: OpenRouter langsung

Ambil kunci di `openrouter.ai/settings/keys`, lalu simpan di `.env` pada folder proyek:

```
cd ~/demo
cat > .env <<'EOF'
OPENROUTER_API_KEY=sk-or-v1-...
LCHAT_MODEL=qwen/qwen3.5-35b-a3b
EOF
chmod 600 .env
echo .env >> .gitignore
```

```
$ cat .env

OPENROUTER_API_KEY=sk-or-v1-CONTOHKEYPALSU1234567890abcdefghijklmnopqrstuvwxyz
LCHAT_MODEL=qwen/qwen3.5-35b-a3b

-rw-rw-r-- 1 developer developer 112 Sep 20 04:56 .env
```

Kalau `OPENROUTER_API_KEY` ada dan `LCHAT_BASE_URL` tidak diisi, lchat otomatis memakai `https://openrouter.ai/api/v1`. Tidak ada langkah lain.

Jaga kunci. Beri izin `600` dan masukkan `.env` ke `.gitignore`. Kunci pada tangkapan layar di atas palsu.

4B Jalur B: lewat LiteLLM proxy

Buat `config.yaml`. Contoh berikut meneruskan ke OpenRouter; untuk model lokal ganti bagian `litellm_params` (lihat catatan di bawah).

```
$ cat config.yaml

model_list:
  - model_name: qwen3.5-35b-a3b
    litellm_params:
      model: openrouter/qwen/qwen3.5-35b-a3b
      api_key: os.environ/OPENROUTER_API_KEY

general_settings:
  master_key: sk-lchat-local

{"status": "healthy", "db": "Not connected"}
```

Jalankan proxy-nya, lalu arahkan lchat ke sana:

```
# terminal 1
export OPENROUTER_API_KEY=sk-or-v1-...
uvx --from 'litellm[proxy]' litellm --config config.yaml --port 4000

# terminal 2 (atau taruh di .env)
export LCHAT_BASE_URL=http://localhost:4000
export LCHAT_API_KEY=sk-lchat-local          # sama dengan master_key di config.yaml
export LCHAT_MODEL=qwen3.5-35b-a3b          # sama dengan model_name di config.yaml
```

```
$ lchat (lewat LiteLLM di localhost:4000)

lchat · qwen3.5-35b-a3b · profil probe:qwen3.5-35b-a3b (~demo/models.json; thinking: body; ctx 64k) · thinking auto
~/demo
mode: ask · setiap write/edit/bash minta izin · Tab ganti mode · Ctrl+V tempel gambar · /help · Ctrl+D keluar

> berapa 17+25? jawab angkanya saja, tanpa tool

... User is asking a simple math question: 17+25. They want just the number as an answer, without using any tools.
...
17 + 25 = 42
...
I should just answer with the number.
42
3.5s · konteks 1.9k/64k tok

>
```

Untuk model lokal, ganti isi `litellm_params`:

```
# vLLM
- model_name: qwen3.5-35b-a3b
  litellm_params:
    model: hosted_vllm/Qwen/Qwen3.5-35B-A3B
    api_base: http://localhost:8000/v1
```

```
# Ollama
- model_name: qwen3.5-35b-a3b
  litellm_params:
    model: ollama_chat/<tag-model>
    api_base: http://localhost:11434
```

Kalau memakai vLLM, jalankan servernya dengan tool parser dan reasoning parser untuk Qwen, agar tool call dan reasoning terpisah rapi. Kalau tidak, lchat tetap bisa membacanya dari teks jawaban, hanya kurang rapi.

5 Kalibrasi model dengan probe

Setiap backend berbeda cara menyalakan dan mematikan mode berpikir. `lchat probe` mencobanya satu per satu, lalu menyimpan hasilnya sebagai profil.

```
lchat probe -m qwen/qwen3.5-35b-a3b --save # hasilnya ke ~/.config/lchat/models.json
```

```
$ lchat probe (langsung ke OpenRouter)
```

```
Profil saat ini: qwen3-openrouter (bawaan; thinking: body; ctx 64k)
```

```
Probe qwen/qwen3.5-35b-a3b @ https://openrouter.ai/api/v1
```

```
default (tanpa switch) reasoning ✓ (field, 420 char)
```

```
reasoning.enabled=true reasoning ✓ (field, 487 char)
```

```
reasoning.enabled=false reasoning ✗
```

```
chat_template_kwargs thinking=true reasoning ✓ (field, 679 char)
```

```
chat_template_kwargs thinking=false reasoning ✓ (field, 508 char)
```

```
prompt /no_think reasoning ✓ (field, 778 char)
```

```
tool call reasoning ✗
```

```
native ✓ (get_weather)
```

```
Hasil: thinking control = body, implicit_open = false, tool_format = [native hermes qwen_xml json_block]
```

```
Saran profil:
```

```
{
  "name": "probe:qwen/qwen3.5-35b-a3b",
  "match": "qwen/qwen3.5-35b-a3b",
  "match_url": "*openrouter.ai*",
  "thinking": {
    "control": "body",
    "on_body": {
      "reasoning": {
        "enabled": true
      }
    },
    "off_body": {
      "reasoning": {
        "enabled": false
      }
    },
    "history": "drop"
  },
  "sampling": {
    "think": {
      "temperature": 0.6,
      "top_k": 20,
      "top_p": 0.95
    },
    "no_think": {
      "temperature": 0.7,
      "top_k": 20,
      "top_p": 0.8
    }
  },
  "tool_format": [
    "native",
    "hermes",
    "qwen_xml",
    "json_block"
  ],
  "ctx": 65536
}
```

Hasil yang sama dijalankan lewat LiteLLM memberi kesimpulan berbeda, dan itulah gunanya probe:

```
$ lchat probe --save (lewat LiteLLM)
```

Profil saat ini: qwen3 (bawaan; thinking: chat_template_kwargs; ctx 64k)

Probe qwen3.5-35b-a3b @ http://localhost:4000

default (tanpa switch)	reasoning ✓ (field, 460 char)
reasoning.enabled=true	reasoning ✓ (field, 547 char)
reasoning.enabled=false	reasoning x
chat_template_kwargs thinking=true	reasoning ✓ (field, 538 char)
chat_template_kwargs thinking=false	reasoning ✓ (field, 529 char)
prompt /no_think	reasoning ✓ (field, 672 char)
tool call	reasoning x
	native ✓ (get_weather)

Hasil: thinking control = body, implicit_open = false, tool_format = [native hermes qwen_xml json_block]

Saran profil:

```
{
  "name": "probe:qwen3.5-35b-a3b",
  "match": "qwen3.5-35b-a3b",
  "match_url": "*localhost:4000*",
  "thinking": {
    "control": "body",
    "on_body": {
      "reasoning": {
        "enabled": true
      }
    },
    "off_body": {
      "reasoning": {
        "enabled": false
      }
    },
    "history": "drop"
  },
  "sampling": {
    "think": {
      "temperature": 0.6,
      "top_k": 20,
      "top_p": 0.95
    },
    "no_think": {
      "temperature": 0.7,
      "top_k": 20,
      "top_p": 0.8
    }
  },
  "tool_format": [
    "native",
    "hermes",
    "qwen_xml",
    "json_block"
  ],
  "ctx": 65536
}
```

Disimpan ke ~/demo/models.json

Di kedua kasus, yang bekerja adalah parameter `reasoning`, sedangkan `chat_template_kwargs` diabaikan. Jalankan probe setiap kali ganti model atau ganti backend.

6 Sesi pertama

Jalankan `lchat` di dalam folder proyek. Baris pertama menampilkan model, profil, dan mode yang aktif.

```
$ lchat

lchat · qwen/qwen3.5-35b-a3b · profil qwen3-openrouter (bawaan; thinking: body; ctx 64k) · thinking auto
~/demo
mode: ask · setiap write/edit/bash minta izin · Tab ganti mode · Ctrl+V tempel gambar · /help · Ctrl+D keluar

> halo, model apa yang kamu pakai? jawab satu kalimat, tanpa tool

! The user is asking me what model I'm using, and they want a one-sentence answer without using any tools. I should respond directly in Indonesian since the user wrote in Indonesian.
Saya adalah model AI yang dirancang untuk membantu coding dan tugas teknis, tetapi saya tidak memiliki informasi spesifik tentang model yang saya gunakan dalam konteks ini.
2.6s · konteks 1.9k/64k tok

>
```

Perintah yang tersedia di dalam sesi:

```
$ lchat → /help

lchat · qwen/qwen3.5-35b-a3b · profil qwen3-openrouter (bawaan; thinking: body; ctx 64k) · thinking auto
~/demo
mode: ask · setiap write/edit/bash minta izin · Tab ganti mode · Ctrl+V tempel gambar · /help · Ctrl+D keluar

> /help
Perintah:
/clear          mulai percakapan baru
/mode [nama]    plan | ask | auto (atau tekan Tab saat mengetik)
/img <path>     lampirkan gambar ke pesan berikutnya
/paste         ambil gambar dari clipboard (sama dengan Ctrl+V)
/model [nama]   lihat / ganti model (profil ikut dipilih ulang)
/profile        tampilkan profil model aktif (JSON)
/think [mode]   auto | on | off
/env           tampilkan konteks environment yang dikirim ke model
/exit          keluar
Akhir baris dengan \ untuk input multi-baris.

>
```

7 Mode kerja dan tombol Tab

Tekan **Tab** saat mengetik untuk berpindah mode: `plan → ask → auto`. Prompt ikut berubah.

Mode	write_file & edit_file	bash
<code>plan</code>	diblokir	minta izin
<code>ask</code> (bawaan)	minta izin	minta izin
<code>auto</code>	langsung jalan	minta izin

```
$ lchat → Tab, lalu model bertanya balik

lchat · qwen/qwen3.5-35b-a3b · profil qwen3-openrouter (bawaan; thinking: body; ctx 64k) · thinking auto
~/demo
mode: ask · setiap write/edit/bash minta izin · Tab ganti mode · /help · Ctrl+C batal · Ctrl+D keluar

auto > buat file konfigurasi linter baru, tapi tanyakan dulu ke saya mau format json atau yaml

! User meminta saya membuat file konfigurasi linter baru, tapi saya harus menanyakan dulu format yang diinginkan (JSON atau YAML). Ini adalah situasi di mana saya perlu meminta pilihan dari user sesuai aturan 10.
Saya akan membuat file konfigurasi linter baru. Sebelum itu, saya perlu menanyakan format yang Anda inginkan.

• ask_user Format mana yang Anda inginkan untuk file konfigurasi linter?
  1) JSON (.json)
  2) YAML (.yaml atau .yml)

jawab (nomor atau teks bebas) > 2
✓ YAML (.yaml atau .yml)

Baik, saya akan membuat file konfigurasi linter dalam format YAML. Untuk proyek Node.js dengan ESM, saya akan membuat file .eslintrc.yaml yang mengonfigurasi ESLint.

• write_file .eslintrc.yaml
  ✓ dibuat · 9 baris

Saya telah membuat file konfigurasi linter .eslintrc.yaml dengan konfigurasi dasar untuk proyek Node.js ESM. File ini mengaktifkan environment ES2024 dan Node.js, serta mengonfigurasi parser untuk mendukung ECMAScript terbaru dengan source type module.

File konfigurasi telah dibuat: .eslintrc.yaml
• [harness] perubahan belum diverifikasi, diingatkan

• bash npm test

  izinkan bash? [y/N/a=selalu]
  o tidak diizinkan
izin ditolak: giliran dihentikan, ketik instruksi berikutnya
95.0s · konteks 2.2k/64k tok

auto >
```

Di contoh itu model memakai `ask_user` untuk menanyakan format file, dan dijawab dengan angka `2`. Jawaban boleh berupa nomor atau kalimat bebas.

8

Plan mode: rencana dulu, baru kerja

Di mode plan, semua perubahan file diblokir sampai kamu menyetujui rencananya. Persetujuan cukup satu tombol.

```
$ lchat --mode plan
```

```
lchat · qwen/qwen3.5-35b-a3b · profil qwen3-openrouter (bawaan; thinking: body; ctx 64k) · thinking auto
```

```
~/demo
```

```
mode: plan · hanya baca, tulis diblokir, rencana diminta persetujuan · Tab ganti mode · /help · Ctrl+C batal · Ctrl+D keluar
```

```
plan > tambahkan fungsi subtract di src/math.js beserta testnya
```

```
! User meminta menambahkan fungsi subtract di src/math.js beserta testnya. Saya perlu:
```

1. Baca file math.js untuk melihat struktur yang ada
2. Baca file math.test.js untuk melihat format test yang digunakan
3. Tambahkan fungsi subtract
4. Tambahkan test untuk subtract
5. Verifikasi dengan npm test

```
! Mari mulai dengan membaca file-file tersebut.
```

```
● read_file src/math.js
```

```
✓ baris 1-3 dari 3
```

```
● read_file src/math.test.js
```

```
✓ baris 1-4 dari 4
```

Saya akan menambahkan fungsi `subtract` ke `src/math.js` dan test-nya ke `src/math.test.js`.

Rencana:

1. Tambahkan fungsi `subtract(a, b)` yang mengembalikan `a - b` ke `src/math.js`.
2. Tambahkan test untuk `subtract` di `src/math.test.js` menggunakan `assert.strictEqual(subtract(5, 3), 2)`.
3. Verifikasi dengan menjalankan `npm test`.

```
● [harness] mode plan: edit_file diblokir (koreksi dikirim)
```

Rencana:

1. Edit `src/math.js`: tambahkan fungsi `subtract(a, b)` yang mengembalikan `a - b` setelah fungsi `sum`.
2. Edit `src/math.test.js`: tambahkan test untuk `subtract` dengan mengimpor `subtract` dan menambahkan test case `subtract(5, 3)` yang harus menghasilkan `2`.
3. Verifikasi: jalankan `npm test` untuk memastikan semua test (termasuk yang baru) lolos.

```
    jalankan rencana ini? [y=ya, mode auto-edit / t=tetap plan] y
```

```
mode: auto-edit (rencana disetujui)
```

```
! User telah menyetujui rencana. Sekarang saya akan melaksanakannya step by step: edit file math.js, edit file math.test.js, lalu verifikasi dengan npm test.
```

```
● edit_file src/math.js
```

```
✓ baris 1
```

```
- export function sum(a, b) {  
-   return a + b;  
- }
```

```
+ export function sum(a, b) {  
+   return a + b;  
+ }
```

```
+
```

```
+ export function subtract(a, b) {  
+   return a - b;  
+ }
```

```
✓ node --check OK
```

```
● edit_file src/math.test.js
```

```
✓ baris 1
```

```
- import { test } from 'node:test';  
- import assert from 'node:assert';  
- import { sum } from './math.js';  
- test('sum', () => assert.strictEqual(sum(1, 2), 3));
```

```
+ import { test } from 'node:test';  
+ import assert from 'node:assert';  
+ import { sum, subtract } from './math.js';
```

```
+ test('sum', () => assert.strictEqual(sum(1, 2), 3));
+ test('subtract', () => assert.strictEqual(subtract(5, 3), 2));
✓ node --check OK

● bash npm test
✓ exit 0 · 0.2s · 14 baris
  □ skipped 0
  □ todo 0
  □ duration_ms 66.197684

Selesai. Fungsi subtract telah ditambahkan ke src/math.js dan test-nya ditambahkan ke src/math.test.js. Semua 2 test (sum dan subtract) lolos.
59.3s · konteks 2.9k/64k tok

auto >
```

9 Mengerjakan tugas nyata

Satu kalimat instruksi sudah cukup. Agent menjalankan test, membaca file, mengedit, lalu menjalankan test lagi untuk membuktikan hasilnya.

```
$ lchat --yolo
```

```
lchat · qwen/qwen3.5-35b-a3b · profil qwen3-openrouter (bawaan; thinking: body; ctx 64k) · thinking auto
```

```
~/demo · /help · Ctrl+C batal · Ctrl+D keluar
```

```
> test-nya gagal, tolong perbaiki
```

```
! User meminta untuk memperbaiki test yang gagal. Saya perlu menjalankan test terlebih dahulu untuk melihat apa yang gagal.
```

Saya akan menjalankan test untuk melihat apa yang gagal.

```
● bash npm test
```

```
✗ exit 1 · 0.3s · 35 baris
  code: 'ERR_ASSERTION',
  actual: -1,
  expected: 3,
  operator: 'strictEqual',
  diff: 'simple'
}
```

Test `sum` gagal. Error menunjukkan expected 3 tetapi actual -1. Saya perlu membaca file `src/math.js` untuk melihat implementasi fungsi `sum`.

```
● read_file src/math.js
```

```
✓ baris 1-10 dari 10
```

Ditemukan masalah: fungsi `sum` menggunakan operator `-` (pengurangan) alih-alih `+` (penjumlahan). Saya akan memperbaiki line 2.

```
● edit_file src/math.js
```

```
✓ baris 1
- export function sum(a, b) {
-   return a - b;
- }
+ export function sum(a, b) {
+   return a + b;
+ }
✓ node --check OK
```

File berhasil diperbaiki. Sekarang saya akan menjalankan test lagi untuk memverifikasi perbaikan.

```
● bash npm test
```

```
✓ exit 0 · 0.3s · 14 baris
  skipped 0
  todo 0
  duration_ms 72.511401
```

Semua test sekarang berhasil.

Fixed: fungsi `sum` menggunakan operator `-` (pengurangan) alih-alih `+` (penjumlahan). Diperbaiki menjadi `a + b`. Semua 2 test sekarang pass.

```
9.6s · konteks 2.6k/64k tok
```

```
> /exit
```

10 Mengirim gambar

Empat cara: **Ctrl+V** (butuh `wl-clipboard` atau `xclip`), `/img <path>`, paste atau drag file ke terminal, dan flag `-i`.

```
lchat -i screenshot.png -p "kenapa layoutnya rusak?"
```

```
$ lchat → Ctrl+V lalu /img

lchat · qwen/qwen3.5-35b-a3b · profil qwen3-openrouter (bawaan; thinking: body; ctx 64k) · think
ing auto
~/demo
mode: ask · setiap write/edit/bash minta izin · Tab ganti mode · Ctrl+V tempel gambar · /help ·
Ctrl+D keluar

>
  clipboard butuh wl-clipboard atau xclip (sudo apt install wl-clipboard); atau ketik /img <path
>

> /img ~/kotak.png

[gambar] kotak.png (png, 751 B) dilampirkan ke pesan berikutnya

> warna apa saja di gambar ini? sebut singkat, tanpa tool
1 gambar dikirim: kotak.png (png, 751 B)

: The user is asking about the colors in the image they provided. They want a brief answer witho
ut using any tools. The image shows a 2x2 grid with 4 colors:
:
: 1. Top-left: Red
: 2. Top-right: Blue
: 3. Bottom-left: Yellow
: 4. Bottom-right: Green
:
: I can answer this directly without needing any tools.
Warna-warna di gambar:

• Merah (kiri atas)
• Biru (kanan atas)
• Kuning (kiri bawah)
• Hijau (kanan bawah)
2.6s · konteks 1.1k/64k tok

>
```

Batas 5 MB per gambar. Saat konteks mulai penuh, gambar lama dibuang lebih dulu karena paling membebani.

11 Izin dan pengaman

Tool yang mengubah sesuatu selalu minta izin: `[y/N/a]`, dengan `a` berarti selalu izinkan tool itu selama sesi.

```
$ lchat (model mencoba membaca .env)

lchat · qwen/qwen3.5-35b-a3b · profil qwen3-openrouter (bawaan; thinking: body; ctx 64k) · thinking auto
~/demo · /help · Ctrl+C batal · Ctrl+D keluar
> apa isi file .env?

| User bertanya tentang isi file .env. Saya perlu membaca file tersebut untuk melihat isinya.
● read_file .env
  ▲ file rahasia: .env. izinkan read_file kali ini? [y/N] n
  ○ tidak diizinkan
izin ditolak: giliran dihentikan, ketik instruksi berikutnya
25.0s · konteks 1.7k/64k tok
> /exit
```

Beberapa aksi ditanyakan **setiap kali**, bahkan dengan `--yolo`: file rahasia, akses di luar folder proyek, dan perintah berbahaya. Kalau tidak ada terminal untuk menjawab, aksinya diblokir.

```
$ lchat --yolo -p "hapus folder src pakai rm -rf"

| User meminta untuk menghapus folder src menggunakan perintah rm -rf. Ini adalah permintaan yang jelas dan langsung. Saya akan menjalankan perintah tersebut.
● bash rm -rf src

  ▲ hapus paksa/rekursif (rm -r/-f). izinkan bash kali ini? [y/N]
Session terminated, killing shell... ...killed.
```

Ini jaring pengaman, bukan sandbox. Perintah berjalan dengan hak akses akunmu, jadi baca dulu apa yang kamu setuju, dan hindari `--yolo` di folder penting.

12 Rujukan singkat

Variabel	Bawaan	Keterangan
<code>OPENROUTER_API_KEY</code>	—	kalau diisi dan base URL kosong, langsung ke OpenRouter
<code>LCHAT_BASE_URL</code>	<code>http://localhost:4000</code>	alamat LiteLLM atau endpoint OpenAI-compatible lain
<code>LCHAT_API_KEY</code>	—	master key LiteLLM
<code>LCHAT_MODEL</code>	<code>qwen3.5-35b-a3b</code>	nama model atau alias di LiteLLM
<code>LCHAT_CTX</code>	dari profil	batas konteks dalam token
<code>LCHAT_TOOL_MAX</code>	<code>8000</code>	batas byte output tool yang dikirim ke model
<code>LCHAT_MODELS</code>	<code>~/.config/lchat/models.json</code>	file profil model

Flag	Keterangan
<code>-p "tugas"</code>	sekali jalan; jawaban ke stdout, aktivitas ke stderr
<code>-i gambar.png</code>	lampirkan gambar (boleh diulang)
<code>-m model</code>	ganti model untuk sesi ini
<code>--mode plan ask auto</code>	mode awal
<code>--yolo</code>	lewati izin biasa (aksi berisiko tetap ditanya)
<code>--think auto on off</code>	kapan model berpikir; bawaannya adaptif
<code>--quiet-think</code> , <code>-v</code> , <code>--raw</code>	sembunyikan reasoning, tampilkan output tool penuh, markdown mentah

Perintah di dalam sesi: `/help`, `/mode`, `/img`, `/paste`, `/model`, `/profile`, `/think`, `/env`, `/clear`, `/exit`.

Tombol: Tab ganti mode, Ctrl+V tempel gambar, panah atas riwayat, Ctrl+W hapus kata, Ctrl+U hapus baris, Ctrl+C batalkan giliran (dua kali untuk keluar), Ctrl+D keluar.

13 Kalau ada masalah

Gejala	Sebabnya biasanya	Tindakan
HTTP 401	key salah atau belum terbaca	cek <code>.env</code> ada di folder kerja, dan nama variabelnya tepat
HTTP 400 ... model	nama model tidak dikenal backend	samakan <code>LCHAT_MODEL</code> dengan <code>model_name</code> di config LiteLLM
Model berpikir terus, lambat	profil salah untuk backend ini	<code>lchat probe --save</code> , atau <code>--think off</code>
Tool call muncul sebagai teks	parser tool di server belum aktif	tetap jalan otomatis; untuk vLLM aktifkan <code>--enable-auto-tool-choice</code>
Ctrl+V tidak melampirkan gambar	alat clipboard belum ada	<code>sudo apt install wl-clipboard</code> atau pakai <code>/img</code>
Jawaban terpotong	batas token output	lchat otomatis meminta model melanjutkan
Konteks penuh	output tool menumpuk	otomatis diringkas; atau <code>/clear</code> untuk mulai bersih